Redes Neuronales biologicamente inspiradas aplicadas al aprendizaje por refuerzo profundo

Adolfo Banchio

February 21, 2026

Director: Dr. Martín A. Domínguez
Facultad de Matemática, Astronomía, Física y Computación (FaMAF)



Estructura de la presentación

Motivación

Marco Teorico

Motivación

Marco Teorico

Contexto

- El Aprendizaje por Refuerzo Profundo ha mostrado resultados sobresalientes y prometedores en areas como:
  - Tareas de control: robotica
  - Juegos Complejos: Atari
  - Entrenamiento de LLMs: fine tunning de chatGPT.
- Predomina el uso de arquitecturas neuronales tradicionales:
  - MLP
  - CNN
  - RNN

¿Que ocurre si utilizamos arquitecturas inspiradas biologicamente?

Antecedentes

Trabajos anteriores buscaron responder dicha pregunta y lograron:

- Integrar una **arquitectura neuronal bioinspirada** (Tap Withdrawal Circuit de *C. elegans*) en el marco del aprendizaje por refuerzo.
- Plantear nuevos modelos de dinamica neuronal (**modelo Fiuri**) y compararlos con modelos estándar (IandF, Izikievich).
- Utilizar metodos de entrenamiento alternativos al descenso por el gradiente (Optimizacion bayesiana, algoritmos geneticos y busquedas aleatoreas).

Nos preguntamos si es posible:

- Implementar de manera eficiente y vectorizada
- Permitir el uso del el descenso por el gradiente
- Integrar a los algoritmos de Deep RL estandar

Objetivo y Desafios

Objetivo

Integrar la arquitectura **TWC + FIU** al framework de PyTorch e intentar resolver un problema de control continuo utilizando un algoritmo estandar Deep RL.

Desafios

- Las arquitecturas bioinspiradas presentan:
  - Dinámica interna recurrente
  - No linealidades inspiradas biológicamente
  - Posibles problemas de diferenciabilidad
- La mayoría de los trabajos previos:
  - Evitan el descenso por gradiente
  - Utilizan métodos evolutivos o búsqueda directa en el espacio de políticas

Motivación

Marco Teorico

Inteligencia Artificial y ML

- Busqueda de **agentes** capaces de tomar la decision correcta en funcion de la información disponible.

Aprendizaje automático (Machine Learning)

Un programa de computadora aprende de la experiencia E con repecto a alguna clase de tareas T y una medida de desempeño P, si su desempeño en tareas de T, medidio por P, mejora con la experiencia E.

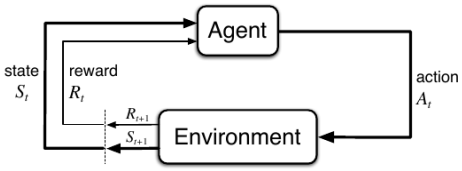
Segun el tipo de experiencia y medida de desempeño, se divide en:

- Aprendizaje supervisado
- Aprendizaje no supervisado
- **Aprendizaje por refuerzo**

Aprendizaje por Refuerzo (RL)

Un agente interactúa con un entorno dinámico donde:

- Observa estados s_t
- Ejecuta acciones a_t
- Recibe recompensas r_{t+1}



Con el objetivo de maximizar la recompensa final acumulada:

$$\max_{\pi} \ \mathbb{E}[R]$$

Principales desafíos:

- Problema de asignación de crédito
- Exploración vs explotación
- Retroalimentación escasa y diferida

Procesos de Decisión de Markov (MDP)

La interaccion **Agente-Entorno** se formaliza mediante un MDP.

Proceso de Decision de Markov

Se define como una tupla ..., donde:

- S
- A
- P
- R
- γ

Propiedad de Markov

El estado actual s_t contiene la informacion necesaria para estimar la posible evolucion del entorno.

Componentes del Aprendizaje por Refuerzo

El Agente toma acciones siguiendo una **Política**: mapeo de estados y observaciones del entorno a una accion que debera tomar el agente.
Objetivo del agente: encontrar la politica que maximice el retorno final.

Retorno y Politica Optima

Dado una secuencia de recompensas $r_{t+1}, r_{t+2} \cdots$, se define el retorno como:

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}$$

La politica optima sera $\pi^* = \arg\max_\pi J(\pi)$ donde $J(\pi) = \mathbb{E}[G_0]$

Componentes del Aprendizaje por Refuerzo

Ecuaciones de Bellman

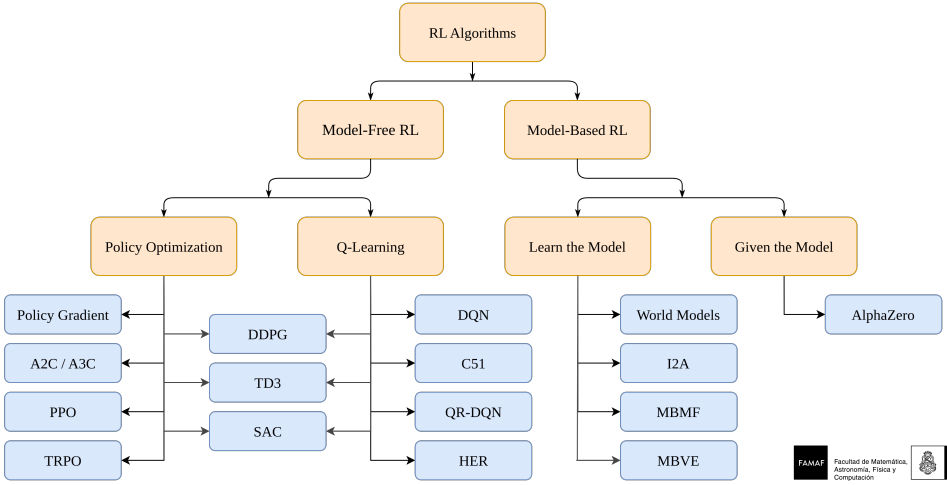
Ecuaciones recursivas que nos permiten estimar la recompensa esperada segun la situacion actual del Agente en el entorno.

- **Función de valor de estado**: estima la recompensa acumulada esperada al partir del estado s y seguir la política π.
  - $V^{\pi}(s) = \mathbb{E}_{\pi}\left[r_{t+1} + \gamma V^{\pi}(S_{t+1}) \mid S_t = s\right]$
- **Función de valor de acción** estima la recompensa acumulada esperada tras ejecutar la acción a en el estado s y continuar siguiendo π.
  - $Q^{\pi}(s,a) = \mathbb{E}_{\pi}\left[r_{t+1} + \gamma Q^{\pi}(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a\right]$.

En espacios de accion continuos:

- Computar $\arg\max_a Q(s,a)$ no es factible
- Se aproximan dichas funciones mediante redes neuronales

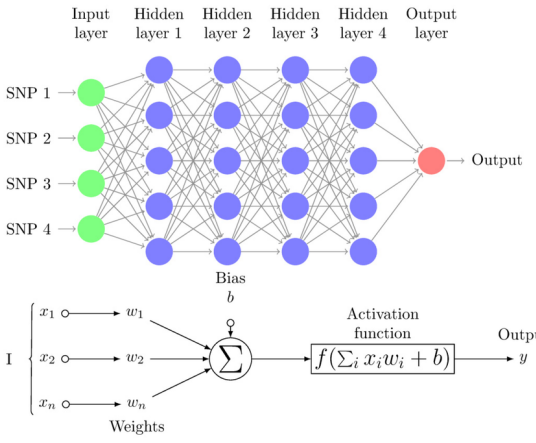
Algoritmos de RL



Redes Neuronales

- Comunmente utilizadas como aproximadores de funciones universales.
- Se entrenan mediante metodos basados en el **descenso por el gradiente**.

$$\theta \leftarrow \theta - \alpha \nabla_\theta L(\theta)$$



Dinamica Neuronal FIU

$$S_n = E_n + \sum_{j=1}^{m} I_{in}^{j}$$

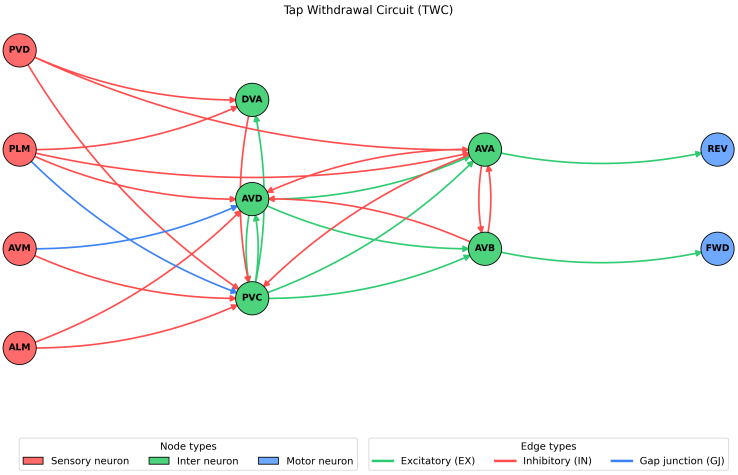
$$O_n = \begin{cases} S_n - T_n, & \text{si } S_n > T_n \\ 0, & \text{en otro caso} \end{cases}$$

$$E_n = \begin{cases} S_n - T_n, & \text{si } S_n > T_n \\ E_n - d_n, & \text{si } S_n \leq T_n \ \wedge \ S_n = E_n \\ S_n, & \text{en otro caso} \end{cases}$$

$$I_{in}^{j} = \begin{cases} \omega_j O_j, & \text{gap junc. y } O_j \geq E_n \\ -\omega_j O_j, & \text{gap junc. y } O_j < E_n \\ \omega_j O_j, & \text{exc. química} \\ -\omega_j O_j, & \text{inh. química} \end{cases}$$

TODO: Ilustracion de una neurona o como fue implementada (placeholder)

La arquitectura TWC



¡Muchas Gracias!

¿Preguntas?

FAMAF Facultad de Matemática, Astronomía, Física y Computación



UNC Universidad Nacional de Córdoba